

고빈도 고객의 재구매 지연 위험 예측

이커머스 주문 이력 기반 재구매 지연 위험 예측 · Binary Classification

팀 이민성

이민성 · 이재형 · 전시훈 · 김재현

Deep Learning Applications · Final Presentation

배경 및 목적

온라인 마켓에서 반복 구매 고객은 매출 기여도가 높은 고객군일 가능성이 크다.
이 고객군의 주문 간격이 평소보다 길어지면 구매 빈도 감소나 장기 미구매의 초기 신호로 볼 수 있다.
따라서 다음 주문이 늦어질 위험을 미리 예측하면 쿠폰, 알림, 추천 등 고객 유지 전략 대상을 선별할 수 있다.

목적

고빈도 고객의 구매 지연 위험을 조기에 탐지해 고객 유지 전략의 우선순위를 정한다.

모델링 문제

과거 주문 이력만 사용해 다음 주문의 target_gap이 15일을 넘는지 예측한다.

예측 구조

구분	정의	핵심
입력	target 주문 이전의 주문 이력	미래 정보 없이 과거 기록만 사용
정답	target 주문의 target_gap	실제로 며칠 뒤 재구매했는지
라벨	target_gap > 15 → 1	15일 초과를 지연 위험으로 정의
출력	delay_risk score	위험 고객 후보를 score로 정렬 가능

예: 25번째 주문이 target이면, 모델은 24번째 주문까지의 기록만 보고 25번째 주문이 15일보다 늦어졌는지를 예측한다.

데이터셋 개요

Instacart는 미국 온라인 장보기 서비스의 공개 주문 데이터셋이다.
 고객별 주문 순서, 주문 요일, 주문 시간, 직전 주문 이후 경과일을 포함한다.
 반복 구매 간격을 직접 계산할 수 있어 '다음 주문 지연 위험' 문제로 전환하기 적합하다.

206,209


전체 고객 수

3,421,083

전체 주문 수

42,499

최종 샘플 수



Instacart 서비스 화면 예시

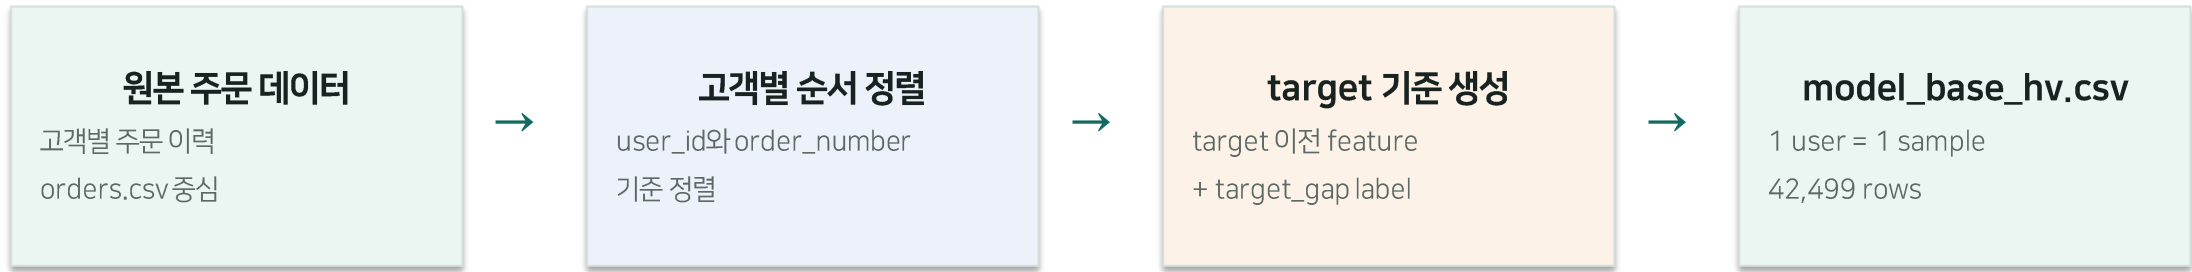
핵심은 고객별 주문 순서와 주문 간격을 이용해 다음 주문 지연 위험을 정의할 수 있다는 점이다.

기본 변수

변수	유형	의미	사용 방식
user_id	ID/범주형	고객 식별자	고객 단위 샘플 구성
order_number	순서형 숫자	고객 내 몇 번째 주문인지	target 이전 주문 순서 구성
days_since_prior_order	수치형	직전 주문 이후 경과일	주문 간격 feature 및 label 생성
order_dow	범주형/순환형	주문 요일	요일 패턴, sin/cos 변환
order_hour_of_day	수치형/순환형	주문 시간대	시간대 패턴, sin/cos 변환
target_gap	수치형	target 주문의 재구매 간격	label 생성용; 모델 입력 아님

target_gap은 모델 입력 변수가 아니라 정답 label을 만들기 위한 변수다.

전처리 흐름



전처리는 고객별 주문 이력을 시간 순서대로 정리한 뒤 target 주문 기준으로 수행했다.
target 주문은 feature 생성에는 쓰지 않고 label 생성에만 사용했다.
최종 기준 데이터 파일은 `model_base_hv.csv`이다.

고빈도 고객 및 타깃 정의

상위 20%

고빈도 고객 기준

24회

최종 모델링 데이터 기준값

15일

운영 라벨 기준

18.65%

positive ratio

분위수 재집계


최종 모델링 데이터 기준 target_gap 분위수는
q80=15일 (80분위수, 초과 구간은 약 상위 20%)
q90=24일, q95=30일이다.

해석

q80=15일은 약 80%의 target_gap이 15일 이하라는 뜻이다. 따라서 15일 초과를 상대적으로 낮은 재구매로 본다.

고빈도 고객군은 총 주문 횟수 상위 20%로 정의했고, 실제 기준값은 24회였다.

데이터 샘플 생성 방식



항목	설정
샘플 단위	1 user = 1 sample
분할 방식	train/valid/test = 70/15/15
샘플 수	29,749 / 6,375 / 6,375
label 비율	positive ratio 약 18.65% 유지

모델 내부 구조가 아니라, target 이전 이력으로 feature를 만들고 target_gap으로 정답 여부를 확인하는 샘플 생성 방식이다.

파생 변수 구성

카테고리	대표 변수	도출 방식	해석
활동성	total_orders_before_target	target 이전 주문 수	고빈도/활동량
평균 주기	avg_gap_before_target, std_gap	이전 gap의 평균/표준편차	평소 구매 주기
최근 패턴	recent_3_avg_gap, recent_5_avg_gap	최근 N회 gap 평균	최근 구매 둔화
직전 신호	last_gap_before_target	target 직전 gap	가장 가까운 위험 신호
추세	gap_trend	최근 gap 변화 방향 요약	간격이 길어지는 흐름
생활 패턴	weekend_order_ratio, dow_variability	주말 비율/요일 다양성	구매 습관 안정성

핵심은 '한 고객의 주문 이력을 숫자로 요약한 표 형태 입력값'과 '최근 주문의 순서 입력값'을 모두 만든 것이다.

주문 Sequence 입력

sequence length

최근 20개 주문

per-order features

gap, gap_delta,
최근 3회 gap 평균

time encoding

요일/시간은 sin, cos로
순환 구조 반영

relative position

target 이전 주문 내
상대적 위치

예시 흐름

3일 → 5일 → 8일 → 14일 → ...

요약 변수는 평균을 보여주지만, sequence 입력은 주문 간격이 어떤 순서로 변했는지를 직접 보여준다.

비교 모델 구성

비교 관점	대표 모델	확인하려는 점
기준선	DummyClassifier, LogisticRegression	최소 기준과 선형 기준선
정형 feature 기반	MLP, CatBoost, LightGBM, XGBoost	고객 요약 정보만으로 충분한가
Sequence-only 딥러닝	LSTM/GRU 계열, TCN, Transformer	최근 주문 흐름만으로 예측 가능한가
Hybrid 딥러닝	HybridGRU	요약 정보와 주문 순서를 함께 쓰면 개선되는가

최종 후보 HybridGRU는 최근 주문 흐름을 읽는 GRU와 고객 요약 feature를 읽는 MLP를 결합한 모델이다.

하이브리드 모델의 핵심 아이디어

Tabular 정보

평균 주문 간격, 활동 기간,
주문 빈도처럼 고객의 장기 성향을 읽는다.

Sequence 정보

최근 주문 간격이 어떤 순서로
늘거나 줄었는지 읽는다.


Fusion

두 결과를 합쳐 다음 주문 지연 위험
score를 계산한다.


단순히 변수를 많이 넣은 것이 아니라, tabular 정보는 MLP가 처리하고 sequence 정보는 GRU가 처리한 뒤 두 결과를 결합한 구조다.

HybridGRU 모델 구조

Sequence 정보



Tabular 정보



핵심

Sequence 정보는 GRU가 읽고, tabular 정보는 MLP가 읽은 뒤
두 결과를 결합해 최종 위험 score를 계산한다.

레이어와 하이퍼파라미터

구성	설정	역할
Sequence input	20 orders × 8 features	최근 주문 흐름 입력
GRU encoder	hidden_dim=128, num_layers=2	순서 패턴 요약
Tabular encoder	13 features → 128 → 64	고객 요약 변수 압축
Fusion	seq embedding 64 + tabular embedding 64	두 정보 결합
Classifier head	128 → 64 → 1	delay_risk logit 출력
Activation	sigmoid	지연 위험 score 변환

학습 설정 및 Threshold 조정

항목	설정
문제 유형	Binary classification
Loss	BCEWithLogitsLoss(pos_weight=4.3621)
Optimizer	AdamW
Learning rate	0.001
Weight decay	0.0001
Batch size	512
Max epochs / early stopping	90 / patience 10
Threshold tuning	validation F1-score 최대화
Final decision threshold	HybridGRU = 0.61 (validation F1 기준)

왜 pos_weight?

positive class가 약 18.65%로 적기 때문에, 자연 위험 고객을 학습에서 더 강하게 반영하기 위해 사용했다.

왜 threshold tuning?


0.5 고정 threshold보다 validation set에서 F1이 가장 높은 기준을 찾았다. 최종 HybridGRU threshold는 0.61이다.

평가 지표

지표	의미	해석 관점
Accuracy	전체 정답 비율	불균형 데이터에서는 과대평가 가능
Recall	위험 고객 중 잡아낸 비율	놓친 위험 고객(FN)을 줄이는 관점
Precision	위험 예측 중 실제 위험 비율	마케팅 비용/오탐 관리
F1-score	Precision과 Recall의 조화 평균	위험 탐지 균형 기준
ROC-AUC	threshold 전반의 구분 능력	순위화 성능 확인
Average Precision	PR curve 요약	positive class가 적을 때 유용

지연 고객 비율이 18.65%로 적기 때문에 accuracy만 보지 않고 Recall, Precision, F1-score를 함께 평가했다.

정형 Feature 모델 결과




CatBoost F1-score: 0.5105

LightGBM Recall: 0.7157로 가장 높음

MLP F1-score: 0.5064로 tree boosting과 근접


LogisticRegression은 선형 baseline으로 성능 차이가 확인됨

Sequence-only 딥러닝 결과



LSTM이 sequence-only 모델 중 F1-score 0.4569로 가장 균형적
 TCN은 Recall이 상대적으로 높았지만 precision은 낮음
 sequence만 사용할 경우 고객의 장기 구매 성향 정보가 약해질 수 있음
 따라서 sequence와 요약 변수를 결합한 하이브리드 구조로 확장

하이브리드 딥러닝 결과




HybridGRU F1-score: 0.5176

sequence-only 최고 LSTM 대비 F1 +0.0607

HybridBiGRU는 ROC-AUC가 가장 높았지만 F1은 낮음

최근 주문 흐름과 고객 요약 feature를 함께 쓰는 구조의 필요성을 확인

전체 모델 비교



핵심 수치


모델	F1	Recall	ROC-AUC
HybridGRU	0.5176	0.6972	0.8220
CatBoost	0.5105	0.6947	0.8226
LightGBM	0.5097	0.7157	0.8181
MLP	0.5064	0.6863	0.8179

0.5176
HybridGRU F1-score

0.7157
LightGBM Recall

해석: CatBoost와의 차이는 크지 않다.
다만 최근 주문 흐름과 고객 요약 feature를 함께 보는
문제 구조에 맞는 딥러닝 최종 후보로 해석했다.

ROC Curve




해석

ROC-AUC는 threshold 전반에서 양성과 음성을 구분하는 순위화 능력을 보여준다.

주의

불균형 데이터에서는 ROC만으로 충분하지 않아 PR curve도 함께 확인했다.

PR Curve




해석

PR curve는 실제 위험 고객이 적은 상황에서 precision과 recall의 trade-off를 더 직접적으로 보여준다.

그래프 해석

모델 간 격차가 크지는 않지만, LogisticRegression과 LSTM은 상대적으로 낮고 tree/hybrid 계열이 상단 밴드를 형성한다.

Confusion Matrix



실제 지연 고객 = TP + FN = 829 + 360 = 1,189명

Recall = TP / (TP + FN) = 829 / 1,189 = 0.6972

즉 실제 지연 고객 중 약 69.7%를 탐지했다는 의미

참고: FP 1,185명은 위험으로 예측했지만 실제 지연되지 않은 고객


이 슬라이드에서는 전체 matrix보다 Recall의 분자와 분모를 중심으로 해석한다.

오류 분석

그룹	target_gap	recent3 gap	last gap	gap_trend	order_freq
FN	23.29	7.84	7.72	0.32	0.14
FP	8.32	13.1	13.75	1.54	0.11
TN	5.96	6.91	6.84	0.17	0.17
TP	25.34	14.35	15.46	2.64	0.11

FP: 실제 지연은 아니지만 최근 gap 신호 때문에 위험으로 판단된 고객
FN: 실제 지연 고객이지만 이전 이력에서 강한 지연 신호가 약했던 고객
이를 통해 어떤 주문 패턴에서 오탐과 미탐이 발생하는지 확인할 수 있다.

Feature 보조 해석



tabular MLP 기준의 보조 해석이다.
상위 신호: active_span_days, recent_3_avg_gap, total_orders_before_target
최종 HybridGRU의 직접 해석은 아니다.

active_span_days = target 이전 첫 주문부터 마지막 주문까지의 고객 활동 기간

성과 해석

1,189명

test set 실제 지연 고객

829명

HybridGRU가 탐지

69.7%

Recall

41.2%

Precision

결과를 쉽게 풀면

실제로 지연된 고객 1,189명 중 829명을 위험 고객으로 잡아냈다.
즉, 위험 고객을 놓치지 않는 관점에서는 약 69.7%를 탐지했다.

주의해서 볼 점

위험으로 예측한 고객 중 실제 지연 고객 비율은 41.2%이다.
따라서 모든 예측이 맞는 모델이라기보다, 위험 고객 후보를 우선 선별하는 모델로 해석한다.

Precision 41.2%는 전체 지연 고객 비율 18.65%와 함께 해석해야 한다.
위험 예측 고객군에는 실제 지연 고객이 평균보다 약 2.2배 더 많이 포함되어 있다.

활용 예: 모든 고객에게 동일하게 쿠폰이나 알림을 보내기보다, 모델이 위험하다고 본 고객부터 먼저 확인하는 방식으로 사용할 수 있다.

※ 실제 운영 효과를 입증한 것은 아니며, 고객 유지 전략 후보를 선별할 가능성을 확인한 결과다.

확장 방향

시간 기준 검증

현재는 동일 split에서 모델 간 공정 비교를 수행했다.

실제 서비스 적용 단계에서는 과거 시점 데이터로 미래 지연을 예측하는 검증을 추가할 수 있다.

개인별 구매 주기 반영

이번에는 해석이 쉬운 공통 기준 $\text{target_gap} > 15$ 를 사용했다.

이후에는 고객별 평균 구매 주기 대비 얼마나 늦어졌는지도 함께 비교할 수 있다.

상품/장바구니 정보 추가

현재 모델은 주문 간격과 순서 정보를 중심으로 구성했다.

상품군, basket size, reorder ratio 등을 추가하면 예측 신호를 더 넓힐 수 있다.

정리하면, 현재 실험은 주문 이력만으로도 지연 위험 고객을 어느 정도 우선순위화할 수 있음을 확인했고, 최종적으로는 더 엄격한 검증 방식과 더 풍부한 feature로 확장할 수 있다.

현재 결과: HybridGRU F1-score 0.5176, Recall 0.6972 · 실제 지연 고객 1,189명 중 829명 탐지

결론 및 활용 가능성

최종 요약

본 프로젝트는 고빈도 고객의 과거 주문 이력을 바탕으로 다음 주문의 재구매 지연 위험을 예측하는 이진 분류 문제를 정의했다.

정형 feature, sequence-only, hybrid 딥러닝 모델을 비교한 결과, HybridGRU는 최근 주문 흐름과 고객 요약 feature를 함께 사용해 sequence-only 모델보다 개선된 성능을 보였고, 같은 split에서 F1 기준 가장 균형적인 결과를 보였다.

0.5176

HybridGRU F1-score

829명

실제 지연 고객 1,189명 중 탐지

CatBoost와의 차이는 크지 않으므로 압도적 우위가 아니라,
문제 구조에 적합한 딥러닝 최종 후보로 해석했다.

기대 효과

위험 score를 기준으로 고객을 정렬하면, 모든 고객에게 동일하게 대응하기보다 쿠폰, 알림, 추천 캠페인을 먼저 적용할 고객군을 선별할 수 있다.